

DILU：基于大型语言模型的自动驾驶知识驱动方法

💡 Tip

DiLu 是首个从人类驾驶角度出发，基于知识驱动能力进行自动驾驶车辆决策的研究。具体而言，驾驶代理利用 **推理模块** 从 **记忆模块** 中查询经验，并借助LLM的常识知识根据当前场景生成决策。随后，它通过 **反思模块** 来判别推理模块产生的决策是否安全，并利用LLM中的嵌入知识对不正确的决策进行修正，最终将这些安全或修正后的决策更新到记忆模块中。

摘要

已有自动驾驶方法主要基于数据驱动的方法，存在 **dataset bias**、**overfitting** 和 **uninterpretability** 等问题。受到人类基于驾驶知识的驾驶模式启发，本文探索如何将类似的能力注入到自动驾驶系统中，并且总结出了一种整合交互环境、驾驶员代理以及记忆组件的范式来解决这一问题。本文提出具有推理和反思模块的 DiLu 框架使得系统能够就常识进行决策并持续进化。DiLu 是首个在自动驾驶决策中利用知识驱动能力的研究，DiLu 能够直接从真实世界数据集中获取经验，凸显了其在真实自动驾驶系统部署中的潜力。

Introduction

- **Data-driven algorithms:** 旨在捕捉和建模累积数据的潜在分布，但始终面临数据集偏差、过拟合和不可解释性等挑战。
- **LeCun (2022):** “Why can an adolescent learn to drive a car in about 20 hours of practice and know how to act in many situations he/she has never encountered before?”：人类驾驶本质上是知识驱动的，而非数据驱动。

数据驱动的方法依赖于大量数据去拟合环境，缺少对环境的理解，限制了模型的泛化能力，同时数据标注成本高昂。

基于上述背景，提出“我们如何将人类驾驶员的知识驱动能力植入自动驾驶系统？”

- LRM 在机器人操作(Driess et al.,2023a; Huang et al.,2023a;b)、多模态理解(Gao et al.,2023)和终身技能学习(Wang et al.,2023; Zhu et al., 2023b)方面展现出强大能力
- 本文提出自动驾驶系统的知识驱动范式，具体由三个组成部分：
 - （1）代理可以与其交互的环境
 - （2）具有记忆、推理和反思能力的驾驶员代理
 - （3）用于持久化记录经验的记忆组件。在持续进化过程中，驾驶员代理通过观察环境、从记忆中查询并更新经验来进行决策




Figure 1: The knowledge-driven paradigm for autonomous driving system, including an interactive environment, a driver agent with recall, reasoning and reflection abilities, along with an independent memory module. Driver agent continuously evolves to observe the environment, query, update experiences from the memory module, and make decisions to control the ego vehicle.

- 本研究设计了一个名为 DiLu 的新型框架，具体而言，驾驶代理利用 **推理模块** 从 **记忆模块** 中查询经验，并借助LLM的常识知识根据当前场景生成决策。随后，它通过 **反思模块** 来判别推理模块产生的决策是否安全，并利用LLM中的嵌入知识对不正确的决策进行修正，最终将这些安全或修正后的决策更新到记忆模块中。

RELATED WORKS

大型语言模型的进展

- GPT-3、PaLM、LLaMA、GPT-4
- 上下文学习
- 指令遵循
- 思维链

基于大型语言模型的高级任务

- Autonomous agents
- 具身大模型

METHODOLOGY

概述

基于上述自动驾驶系统的知识驱动范式，我们提出 DiLu 框架，包含四个核心模块：环境、推理、反思和记忆。

- 推理模块可以观察环境，并结合场景描述与从记忆模块检索到的类似情境的少样本经验生成提示词，提示词输入给 LLM，解码 LLM 输出获得动作决策
- 反思模块评估这些决策，根据经验识别不安全决策
- 修改过的决策经验被更新至记忆模块




Figure 2: The framework of DiLu. It consists of four modules: Environment, Reasoning, Reflection, and Memory. In DiLu, the Reasoning module can observe the environment, generate prompts by combining scenario descriptions and experiences in the Memory module, and decode responses from the LLM to finish decision-making. Concurrently, the Reflection module evaluates these decisions, identifies the unsafe decision to the experiences, and finally updates the revised experiences into the Memory module.

记忆模块

- 在缺乏少样本经验（**few-shot experiences**）的情况下，开箱即用的LLMs在处理复杂闭环驾驶任务时无法进行精确推理。
- 使用记忆模块来存储过往驾驶场景中的经验，这些经验包括决策提示词、推理过程以及其他有价值的信息。记忆模块中存储的记忆由两部分组成：场景描述和对应的推理过程：
 - 场景描述对当前情况进行了详细描述，作为记忆模块检索相似记忆的关键。
 - 推理过程则记录了处理该情况的适当方法，这是记忆的价值所在，引导智能体走向正确的驾驶逻辑

记忆模块的构建分为三个阶段:初始化、记忆检索和记忆存储

H5 初始化

记忆模块的初始化类似于人类在上路前参加驾驶培训。我们选择几个典型场景，并手动规划这些情境下的正确推理与决策流程，从而形成初始记忆。这些记忆会指导代理在驾驶过程中做出正确的决策流程。

H5 记忆回溯

在每个决策帧中，智能体会收到驾驶场景的文本描述。在做出决策前，当前驾驶场景被嵌入为一个向量，并将该向量作为记忆键。随后通过聚类 and 搜索，在记忆模块中查找与该键最相近的场景(John-son et al., 2019)及其对应的推理过程(即记忆)。这些通过回溯得到的记忆将以少样本形式提供给智能体，辅助其对当前场景进行准确推理和决策。

H5 记忆存储

当智能体进行正确推理和决策，或反思正确的推理过程时，它会获得驾驶经验。我们将场景描述的嵌入向量作为键，将其与推理过程配对，形成并存储为记忆模块中的记忆。

推理模块

在推理模块中，我们利用记忆模块中获取的经验知识以及LLM的常识知识，对当前交通场景进行决策。具体而言，推理过程如下图所示，包括以下步骤:

- 通过描述器对场景进行编码
- 从记忆模块中调取若干经验
- 生成提示
- 将提示输入LLM
- 从LLM的响应中解码动作




Figure 3: Reasoning module. We leverage the LLM’s common-sense knowledge and query the experiences from Memory module to make decisions based on the scenario observation.

H5 通过描述器对场景进行编码

为便于 DiLu 理解当前交通状况，场景描述器将当前场景数据转录为描述性文本。该描述器遵循标准句式结构，使用自然语言对当前驾驶场景进行详尽描述。此描述包含场景中的静态道路细节，以及自身车辆和周围车辆的动态信息。生成的描述随后将用作提示词生成器的输入，并作为从记忆模块获取相关少样本经验的检索键。

H5 从记忆模块中调取若干经验

在推理过程中，当前驾驶场景的描述会被嵌入为一个向量，如上图所示。该向量随后被用于在记忆模块中发起相似度查询来寻找最相似的前 k 个情境。得到的配对场景描述与推理过程组合成少样本经验，随后被整合到提示词生成器中。

H5 生成提示词

如上图中蓝色虚线框所示，每个帧的提示包含三个关键组件：**系统提示词**、**来自场景描述器的文本描述**以及**少样本经验**。在系统提示词中，我们提供了闭环驾驶任务的简要概述，包括任务输入和输出的内容及格式介绍，以及推理过程的约束条件。在每个决策帧中，我们基于当前驾驶场景构建定制化提示词。这些提示词随后被用作 LLM 的推理输入并确定当前帧的适当操作。

H5 将提示词输入 LLM

由于闭环驾驶任务需要复杂的推理过程来做出合理决策，我们采用了 Wei 等人(2022年)提出的思维链(CoT)提示词技术。该技术要求 LLM 生成一系列描述逐步推理逻辑的句子，最终导向最终决策。这一方法的采用是由于驾驶场景的内在复杂性和可变性，如果语言模型直接生成决策结果可能导致幻觉。此外，生成的推理过程有助于反思模块对错误决策进行进一步修正和调整。

将提示词输入 LLM 后,我们通过动作解码器解析最终决策。动作解码器将 LLM 的决策结果转化为自动驾驶车辆的动作,并向环境提供反馈。通过重复上述 步骤,我们建立了一个闭环决策系统。



Figure 4: (a) The textual scenario description generated by the scenario descriptor, (b) The decision decoder decodes the action with the output of LLM reasoning.

反思模块（持续学习、增量学习）

在推理模块中,我们利用大语言模型(LLM)在记忆模块支持下执行闭环驾驶任务。下一步,我们希望在驾驶会话结束后能够积累宝贵的驾驶经验并丰富记忆模块。为实现这一目标,我们在 DiLu 中提出了反思模块,该模块能够持续从过去的驾驶经验中学习。DiLu 可以通过反思模块逐步提升性能,类似于新手成长为经验丰富的驾驶员的过程。

反思模块如下图所示,在闭环驾驶任务中,我们记录基于驾驶场景描述的提示词输入以及 LLM 为每个决策帧生成的对应决策。当驾驶会话结束时,我们将获得一个决策序列。例如下图中 0 到 4 的 5 个决策帧。若会话结束时未发生碰撞或危险事件,表明会话成功,DiLu 将从序列中采样若干关键决策帧。这些帧将直接成为历史驾驶经验的一部分,并用于丰富记忆模块。

相反,如果当前会话因与其他车辆碰撞等危险情况而终止,这表明驾驶代理做出了不正确的决策。系统必须纠正推理模块做出的不安全决策。得益于可解释的思维链响应,我们可以轻松找到危险情况的原因。当然,我们可以请人类专家完成此类纠错过程。然而,我们的目标是让自动驾驶系统自主学习如何从错误中吸取教训。我们发现,LLM(大语言模型)可以有效充当纠错器。我们的方法是将发生错误决策的驾驶场景与原始推理输出一起作提示词输入给 LLM。我们要求 LLM 找出错误决策背后的原因并提供正确的决策,同时我们还要求 LLM 提出策略以避免未来出现类似错误。最后,从错误中学习到的正确推理过程和修正后的决策将被保留到记忆模块。




Figure 5: Reflection module. The Reflection module takes recorded decisions from closed-loop driving tasks as input, it utilizes a summarization and correction module to identify safe and unsafe decisions, subsequently revising them into correct decisions through the human knowledge embedded in LLM. Finally, these safe or revised decisions are updated into Memory module.

EXPERIMENTS

实验验证过程中，我们采用了广为人知的 Highway-env 作为模拟环境，该环境是自动驾驶和战术决策领域广泛应用的平台 (Leurent, 2018)。此环境提供了多种驾驶模型，并构建了一个真实的多车辆交互环境。此外，车辆的密度和车道数量在环境中可以自由调整。

- 推理模块：GPT-3.5
- 反思模块：GPT-4
- 记忆模块：向量数据库 Chroma
- 场景描述：text-embedding-ada-002

在 highway-env 的模拟器设置方面，我们直接从模拟器 API 中获取车辆信息并将其输入场景描述器。这些信息仅包含当前帧中每辆车的位置、速度和加速度数据，但不包含任何决策意图或潜在风险信息，如下图所示。元动作被用作我们实验中的决策输出，包含五个离散动作来控制自身车辆：加速、保持速度、减速以及向左和向右的车道变换。对于每个闭环驾驶任务，我们定义成功完成时间为30秒，决策频率为1Hz。这意味着如果本车能在30秒内以合理速度安全行驶且不发生碰撞，则认为任务成功完成。除非另有说明，我们的实验环境采用车辆密度为 2.0 的四车道高速公路，代表交通密度和复杂度相对较高的场景。所有其他设置均遵循模拟器的默认配置。

Highway-env



System Prompts

You are ChatGPT, a large language model trained by OpenAI. Now you act as a mature driving assistant, who can give accurate and correct advice for human driver in complex urban driving scenarios. You will be given a detailed description of the driving scenario of current frame along with your history of previous decisions. You will also be given the available actions you are allowed to take. All of these elements are delimited by ####.

Your response should use the following format:

```
<reasoning>
<reasoning>
<repeat until you have a decision>
```

Response to user:#### <only output one `Action\_id` as a int number of you decision, without any action name or explanation. The output decision must be unique and not ambiguous, for example if you decide to decelerate, then output `4`>

Make sure to include #### to separate every step.

Few-shot experiences

#1 Experience:

Human Questions:
LLM response:

#2 Experience:

Human Questions:
LLM response:

...

#k Experience:

Human Questions:
LLM response:

Scenario Description

Above messages are some examples of how you make a decision successfully in the past. Those scenarios are similar to the current scenario. You should refer to those examples to make a decision for the current scenario.

Here is the current scenario:

Driving scenario description:

{scenario_description}

Driving Intentions:

{driving_intentions}

Available actions:

{available_actions}

You can stop reasoning once you have a valid action to take.

You are driving on a road with 4 lanes, and you are currently driving in the leftmost lane. Your current position is `(408.13, 0.00)`, speed is 24.03 m/s , acceleration is -0.05 m/s^2 , and lane position is 408.13 m .

There are other vehicles driving around you, and below is their basic information:

- Vehicle `992` is driving on the lane to your right and is ahead of you. The position of it is `(422.72, 4.00)`, speed is 17.25 m/s , acceleration is -1.33 m/s^2 , and lane position is 422.72 m .

- Vehicle `712` is driving on the same lane as you and is ahead of you. The position of it is `(442.23, 0.00)`, speed is 22.84 m/s , acceleration is -1.49 m/s^2 , and lane position is 442.23 m .

Your driving intention is to drive safely and avoid collisions

Your available actions are:

IDLE - remain in the current lane with current speed Action_id: 1
Turn-right - change lane to the right of current lane Action_id: 2
Acceleration - accelerate the vehicle Action_id: 3
Deceleration - decelerate the vehicle Action_id: 4

Figure 8: The prompts template for reasoning module. The prompts in the grey box are fixed, while the prompts in the coloured box are different depending on the current scenario. The few-shot experiences are detailed demonstrated in Figure 9.

Human Question:

Here is the #1 scenario:

Driving scenario description: Description of the scene, omitted here...

Driving Intensions: Description of the intension, omitted here...

Available actions: Description of the available actions, omitted here...

You can stop reasoning once you have a valid action to take.

LLM response:

I have 4 actions to choose from. Now, I would like to know which action is possible.

I should first check if I can accelerate, then idle, finally decelerate. I can also try to change lanes but with caution and not too frequently.

- I want to know if I can accelerate, so I need to observe the car in front of me on the current lane, which is car `176`. The distance between me and car `176` is $464.26 - 432.15 = 32.11$ m, and the difference in speed is $20.98 - 24.00 = -3.02$ m/s. Car `176` is traveling 32.11 m ahead of me and its speed is 3.02 m/s slower than mine. This distance is safe and my speed is already higher than the front car on the current lane. So I should not accelerate.

- Since I cannot accelerate, I want to know if I can maintain my current speed. I need to observe the car in front of me on the current lane, which is car `176`. Due to above calculation, the distance between me and car `176` is 32.11 m, and the difference in speed is -3.02 m/s. The distance 32.11 m is larger than my preferred car following distance 30 m, and my speed is higher than the front car on the current lane. So I can maintain my current speed.

Great, I can make my decision now. Decision: IDLE

Response to user:#### 1

#1 Experience

Human Question:

Here is the #2 scenario:

Driving scenario description: Description of the scene, omitted here...

Driving Intensions: Description of the intension, omitted here...

Available actions: Description of the available actions, omitted here...

You can stop reasoning once you have a valid action to take.

LLM response:

I have 5 actions to choose from. Now, I would like to know which action is possible.

I should first check if I can accelerate, then idle, finally decelerate. I can also try to change lanes but with caution and not too frequently.

- I want to know if I can accelerate, so I need to observe the car in front of me on the current lane, which is car `952`. The distance between me and car `952` is $422.15 - 399.89 = 22.26$ m, and the difference in speed is $14.08 - 24.03 = -9.95$ m/s. Car `952` is traveling 22.26 m ahead of me and its speed is 9.95 m/s slower than mine. This distance is safe and my speed is already higher than the front car on the current lane. So I should not accelerate.

- Since I cannot accelerate, I want to know if I can idle. I need to observe the car behind me on the current lane, which is car `776`. The distance between me and car `776` is $399.89 - 411.68 = -11.79$ m, and the difference in speed is $24.03 - 23.90 = 0.13$ m/s. Car `776` is traveling 11.79 m behind me and its speed is 0.13 m/s slower than mine. This distance is too close and my speed is already higher than the rear car on the current lane. If I idle, the distance between me and car `776` will be further smaller, so I should not idle.

- In order to keep a safe distance with the rear car, I can only decelerate. Deceleration is a feasible action.

Great, I can make my decision now. Decision: Deceleration

Response to user:#### 4

#2 Experience

Human Question:

Here is the #3 scenario:

Driving scenario description: Description of the scene, omitted here...

Driving Intensions: Description of the intension, omitted here...

Available actions: Description of the available actions, omitted here...

You can stop reasoning once you have a valid action to take.

LLM response:

I have 5 actions to choose from. Now, I would like to know which action is possible.

I should first check if I can accelerate, then idle, finally decelerate. I can also try to change lanes but with caution and not too frequently.

- I want to know if I can accelerate, so I need to observe the car in front of me on the current lane, which is car `464`. The distance between me and car `464` is $532.46 - 464.36 = 68.10$ m, and the difference in speed is $22.10 - 24.00 = -1.90$ m/s. Car `464` is traveling 68.10 m ahead of me and its speed is 1.90 m/s slower than mine. This distance is safe and my speed is already higher than the front car on the current lane. So I should not accelerate.

- Since I cannot accelerate, I want to know if I can maintain my current speed. I need to observe the car in front of me on the current lane, which is car `464`. Due to above calculation, the distance between me and car `464` is 68.10 m, and the difference in speed is -1.90 m/s. The distance 68.10 m is higher than my preferred car following distance 30 m, and my speed is higher than the front car on the current lane. So I can maintain my current speed.

Great, I can make my decision now. Decision: Idle

Response to user:#### 1

#3 Experience

Figure 9: The 3-shot prompts example for the scenario shown in Figure 8. DiLu recall top three most similar experience from the memory module which contains 2 idle and 1 deceleration decision. The 3-shot experience is entered into GPT-3.5 as a "human-LLM" dialogue.

DILU 框架的验证

在本节中,我们主要验证 DiLu 框架的有效性,特别是验证有无记忆模块的推理与反思过程。未配备记忆模块的 DiLu 框架称为0-shot基线,我们通过1-shot、3-shot和5-shot实验对比,证明经验积累的必要性。初始记忆模块包含5个人工设计的经验。这些经验随后在不同少样本设置中用于推理与反思,实现经验的持续积累与更新。我们分别测试记忆模块包含5、20和40条经验时的对比实验,每个设置采用不同随机种子重复10次。结果以箱线图形式

展示于下图。成功步骤(SS)表示连续无碰撞的帧数，SS为30表示自动驾驶车辆完成驾驶任务。我们发现，**随着记忆模块中经验数量增加，DiLu 框架在所有少样本设置下的性能均提升**。值得注意的是，在20个经验场景中，5-shot设置多数情况下能成功完成闭环驾驶任务。当记忆模块配备40个经验时，所有试验的中位SS值均超过25。相比之下,当框架缺少记忆模块进行0-shot实验时，所有任务均未成功，中位SS值低于5。这表明 LLM 无法在无适应情况下直接完成闭环驾驶任务。

此外，我们观察到，在固定经验记忆数量的情况下，框架的性能会随着少样本经验提取数量的增加而提升。具体而言，当经验记忆为40条时，5-shot 框架几乎通过了所有测试，而3-shot 和 1-shot 框架的中位数SS分别为27和25。这可归因于更高的少样本数量包含了在相似驾驶场景中多样化的经验。当作为提示输入到 LLM 中时，这些经验使 LLM 能够利用更广泛的信息和决策策略，从而促进更理性的决策。




Figure 6: (a) Quantitative experiments with different experiences in Memory module and different few-shot numbers. Notably, the 5-shots setting achieve a maximum(30) simulation steps with both 20 and 40 memory items. (b) Generalizability experiment on environment with different traffic density using 20 memory items.

与强化学习方法的比较

我们在 Highway-env 环境中对 DiLu 与最先进的强化学习(RL)方法GRAD(Graph Representation for Autonomous Driving)(Xi & Sukthankar, 2022)进行了对比实验。GRAD是一种专门为自动驾驶场景设计的基于RL的方法，其生成的全局场景表示包含对其他车辆未来轨迹的估计预测。我们基于lane-4-density-2 设置对 GRAD 进行了训练，即 4 车道高速公路场景且车辆密度为 2.0。作为对比，DiLu使用了完全来自 lane-4-density-2 设置的 40 条经验。我们将成功率(SR)定义为无碰撞驾驶持续 30 个决策帧，并在三种环境设置下进行实验:lane-4-density-2、lane-5-density-2.5和lane-5-density-3。每个设置包含10个随机不同种子的测试场景。

结果如下图(a)所示，首先,在 lane-4-density-2 设置下，DiLu 仅通过 Memory 模块中的 40 条经验就实现了 70% SR，而GRAD在经过600,000次训练回合后收敛至 69% SR。我们发现 GRAD的许多失败是由于无法及时制动，导致与前车发生碰撞。这是因为强化学习方法倾向于拟合环境，未能考虑类人驾驶知识。其次，我们将在 lane-4-density-2 训练的DiLu和

GRAD迁移至 lane-5-density-2.5 和 lane-5-density-3 环境。我们观察到，随着车道数量变化和交通密度增加，两种方法在迁移环境中的性能均出现不同程度下降。然而在最复杂的lane-5-density-3环境中，DiLu无需额外优化仍保持 35% SR，而GRAD性能下降达 85%。这说明 DiLu 在一个环境中积累的经验可泛化至另一环境，而强化学习方法容易过拟合训练环境。




Figure 7: (a) Performance comparison with GRAD in different types of motorway environments. Both two methods are **only** optimized on lane-4-density-2 settings and evaluate on lane-4-density-2, lane-5-density-2.5 and lane-5-density-3 respectively. (b) Experiments with experience from different domains.

通用和迁移实验

数据驱动的方法通常会过拟合训练环境，而 **人类知识应具有领域无关性，并能推广到不同环境**。我们进行了多项实验来评估 DiLu 的泛化和迁移能

H5 不同环境下的泛化能力。

我们验证了从 DiLu 的记忆模块中获得的经验是否具备泛化能力。更准确地说，我们使用来自 lane-4-density-2 环境的20个经验，在lane-5-density-3设置下进行实验，分别测试了 3-shot 和 5-shot 的闭环性能。实验结果如上上图(b)所示。可以看到，DiLu的 3-shot 版本在 lane-4-density-2设置下获得13的中位SS值，而在lane-5-density-3设置下降至5的中位SS值。但在5-shot版本中，我们在相同情况下实现了中位SS值下降30→23。这表明，向 LLM 输入更多样本经验能提升泛化能力。

H5 利用真实世界数据集的转换能力

由于DiLu的记忆模块以自然语言文本形式存储经验，其中包含可直接迁移至不同环境的环境无关知识。为展示此能力，我们创建了两个记忆模块，每个模块包含从两个不同来源提取的20个经验：

- (1)Highway-env
- (2)CitySim (Zheng等,2023年提出的包含真实世界车辆轨迹数据的数据库)

随后我们在Highway-env环境中的场景lane-4-density-2 和lane-5-density-3上对这些模块进行了评估。实验结果如上图(b)所示。与没有任何先验经验的系统(用灰色点划线表示)相比，CitySim贡献的知识也提升了DiLu的性能。此外，在将经验迁移到更拥堵的环境(从lane-4-density-2到lane-5-density-3)时，来自现实世界数据的记忆相较于仅在模拟领域内积累的记忆展现出更强的鲁棒性。

反射模块中两种记忆类型的效用

在本节中，我们通过消融研究探讨了在反思模块中整合成功经验和修正的不安全经验的意义。我们采用包含 20 条初始经验的记忆模块，并观察新记忆积累过程中的性能变化。结果如下表所示，基线表示使用包含20个初始经验的记忆模块的系统，然后我们依次将12个成功记忆和6个纠正记忆添加到基线中。在实验中，基线成功步数中位数仅为10。然而，在更新新经验后，两种方法均实现了超过20的成功步数中位数，且同时采用两种类型经验的方法在所有统计指标上均表现出更高的成功步数。因此，在反思过程中添加两种不同类型的经验既合理又有效。

Table 1: Effectiveness of two memory types in the Reflection module on Success Steps. MIN, Q1, Median, Q3, MAX means the quartile statistical evaluation.

Methods	MIN	Q1	Median	Q3	MAX
baseline	2.0	3.0	10.0	22.0	30.0
+success_memory	3.0	7.0	24.5	29.3	30.0
+correction_memory	4.0	7.75	21.5	30.0	30.0
+both_type_memory	5.0	7.8	24.5	30.0	30.0

CONCLUSION

在本文中，我们探索了将人类认知级别的知识注入自动驾驶系统。我们总结了一个知识驱动范式，并提出了DiLu框架，其包含用于记录过往驾驶经验的记忆模块，以及配备推理和反思模块的代理。大量实验结果展示了 DiLu 持续积累经验的能力，并在与基于 RL 的 SOTA 方法对比中表现出强大的泛化能力。此外，DiLu 直接从真实世界数据集获取经验的能力，凸显了其在实际自动驾驶系统部署中的潜力。DiLu 框架虽有效，但也存在局限性。

目前其决策延迟为**5-10秒**，包含**LLM推理和API响应时间**。此外，本研究并未完全消除 LLMs 的生成幻觉问题。未来改进可借助大模型压缩与优化方面的最新进展，旨在提升效率与效果。